

Final Project

丁文超

准备工作

数据来源包括 Hugging Face、数据集官网和项目仓库。
HF 数据加载可参照 快速入门 - Hugging Face 中文。

如果你在下载 HF 数据集时遇到问题，可以设置镜像

Linux
export HF_ENDPOINT=https://hf-mirror.com

Windows Powershell
$env:HF_ENDPOINT = "https://hf-mirror.com"

难度划分

结合实际复现的流程复杂度、排错与评测要求分级

基础 ★

任务边界明确，完成规范实验

复用成熟方法，完成规范比较并解释失败案例

提高 ★★

引入真实约束，比较方案取舍

在数据预算、分布变化或排序约束下设计实验

进阶 ★★★

复杂问题建模，开展系统评估

涉及多模块集成、闭环控制或多条件系统评测

七个候选项目

按本轮复现的综合工作量由易到难排列

01　外汇预测（Foreign Exchange）

基础　时序划分与滚动评测

02　科学文献语义检索与重排序

基础　语义表示与相关性评估

03　基于正常样本的工业缺陷检测

提高　异常检测与缺陷定位

04　少交互用户的电影推荐

提高　推荐排序与少交互用户建模

05　有限标注预算下的主动学习

提高　逐轮选样与实验设计

06　模态缺失下的多模态情感分析

进阶　缺失感知融合与系统评估

07　机器人模仿学习：Lift 与推 T

进阶　Lift 必做；推 T 进阶选做

1. 外汇预测（Foreign Exchange）

基础 ★　时序预测、跨时期泛化与滚动评测

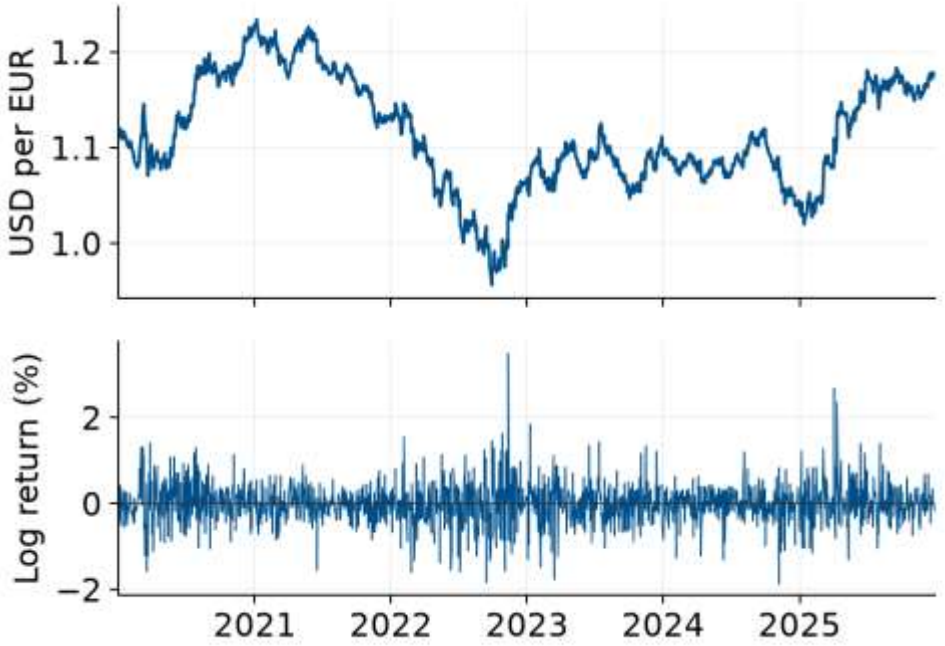
数据准备

ECB 日度参考汇率，固定 EUR/USD
统一历史区间，预测下一有效观测日

欧洲央行：历史参考汇率与下载说明
历史 CSV 数据下载（ZIP）

任务定义

输入：过去一段时间每天的 EUR/USD 汇率
窗口长度自选，如 5、20、60 个交易日
输出：下一交易日相对今天的涨跌幅



ECB 真实汇率与日对数收益率，2020–2025

基线与比较

简单基线：用当前汇率预测下一日汇率
即假设下一日汇率不变

评测与完成标准

按时间划分数据，验证集选参数
逐日预测下一交易日，与真实涨跌幅比较
汇总测试期及各年度 MAE、RMSE（越低越好）
比较窗口与模型，不要求超过基线

2. 科学文献语义检索与重排序

基础 ★　语义表示与相关性评估

数据准备

SciFact：科学论断、文献及相关性标注

标注给出每条论断对应的相关文献

语料：huggingface.co/datasets/BeIR/scifact

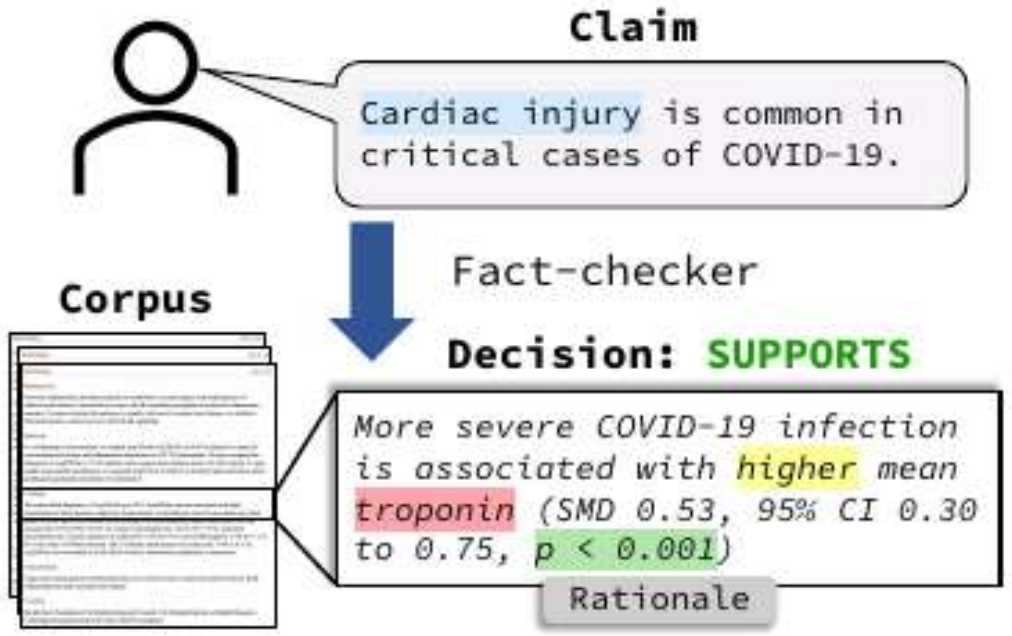
标注：huggingface.co/datasets/BeIR/scifact-qrels

任务定义

从给定文献库中找出与论断相关的文献

输入：一条科学论断和待检索文献库

输出：按相关程度排序的前 10 篇文献



SciFact 原论文图 1：论断与证据示例

基线与比较

比较关键词检索 BM25

用已有的预训练向量检索微调，或者自己训练一个

在相同的测试集上比较

评测指标

Recall@10：前 10 篇找回多少相关文献

NDCG@10：相关文献是否排在前面

同时报告每次检索耗时

3. 基于正常样本的工业缺陷检测

提高 ★★　异常检测与缺陷定位

数据准备

MVTec AD，基础自选一个类别
仅用正常样本训练；多类别为进阶选做

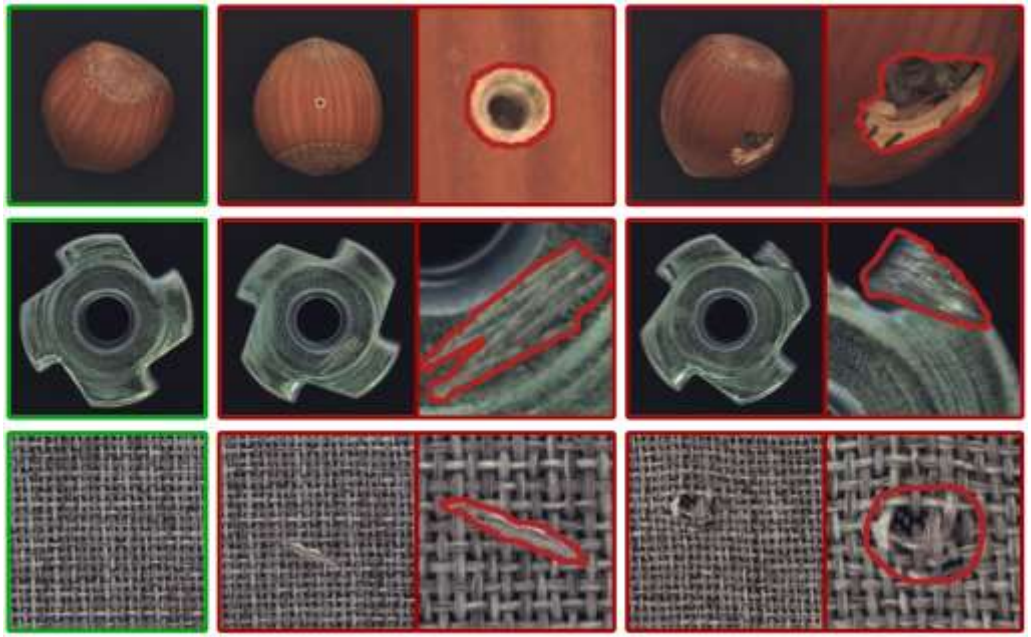
数据下载：MVTec AD 社区镜像
HF 源仓库：foersben/mvtec-ad

任务定义

仅学习正常图片，在测试图片中寻找缺陷

输入：一张待检测产品图片

输出：异常分数和标出疑似缺陷位置的热力图



MVTec AD 原论文：正常样本与缺陷

基线与比较

比较至少两种异常检测方法
分析正常训练样本数量对检测效果的影响

评测指标

图像 AUROC：区分正常图片与缺陷图片
像素 AUROC：区分正常位置与缺陷位置
两项均越高越好，用测试标注评价

4. 少交互用户的电影推荐

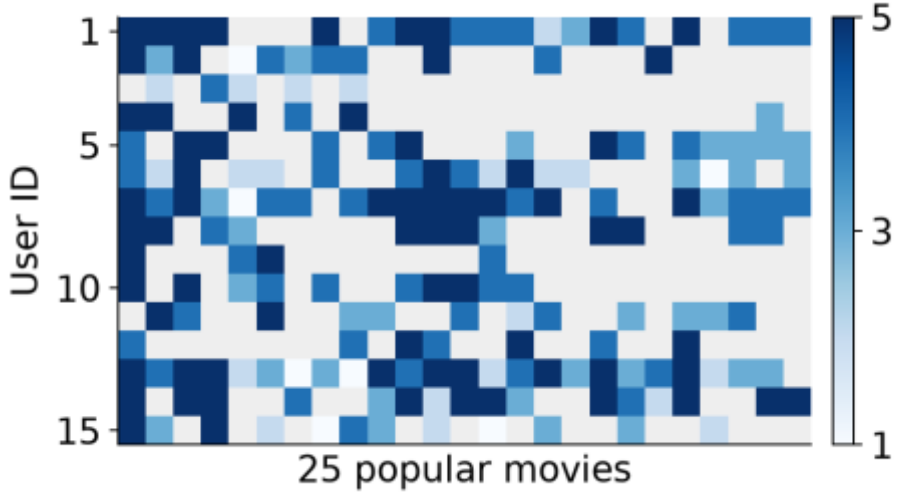
提高 ★★　推荐排序与少交互用户建模

数据准备

MovieLens 100K：用户评分与电影类别

分别只给每位测试用户 1、3、5 条历史评分

grouplens.org/datasets/movielens/100k/



MovieLens 真实评分子集，灰色为未评分

任务定义

根据少量评分，推荐用户可能喜欢的电影

输入：用户历史评分及电影类别

输出：未出现在可见历史中的 10 部电影

基线与比较

热门推荐作为基线（数据集中评分多电影）

训练协同过滤模型，输入电影类别、历史评分等信息，

比较不同历史记录数量下的 Top-10 推荐效果。

评测指标

用隐藏的喜欢记录评价推荐结果

Recall@10：找回比例；NDCG@10：排序质量

覆盖率：所有推荐涉及多少种电影

5. 有限标注预算下的主动学习

提高 ★★　样本选择与实验设计

数据准备

CIFAR-10 图片分类，先隐藏部分训练标签

每轮选中图片后，才允许使用其已有标签

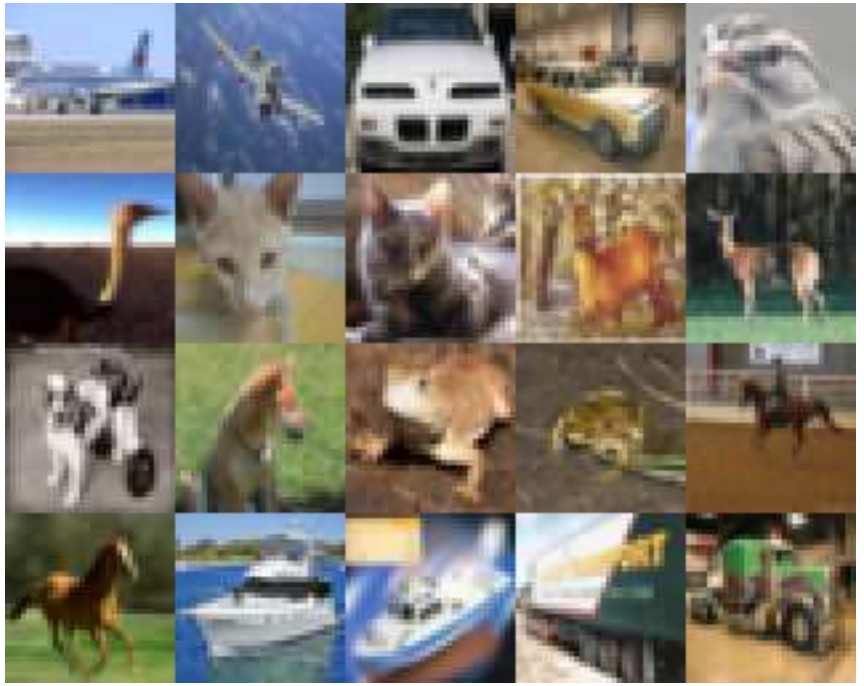
huggingface.co/datasets/uoft-cs/cifar10

任务定义

循环：选图片、获取标签、重新训练分类器

输入：已有标签的图片、待选图片和预算

输出：每轮选中的图片及训练后的分类器



CIFAR-10 官网样例，原始分辨率 32×32

基线与比较

随机选样作为基线

比较不确定性等至少一种主动选样策略

评测指标

在同一独立测试集上评价分类准确率

画出准确率随累计标注图片数的变化

比较达到同一准确率所需的标注量

6. 模态缺失下的多模态情感分析

进阶 ★★★　缺失感知融合与系统评估

数据准备

CMU-MOSI 多模态情感数据

固定数据划分，使用 MMSA 预提取特征

特征下载：CMU-MOSI 社区镜像

特征来源与说明：MMSA 作者仓库

任务定义

输入：视频片段的文本、声音、画面特征

并注明哪些信息缺失（可用性掩码）

输出：情感分数（−3 消极，+3 积极）



CMU-MOSI 原论文中的视频帧样例

基线与比较

比较只用一种信息、特征拼接及自选融合

测试时分别去掉一种信息，再随机模拟缺失

比较多档缺失比例，固定相同测试样本

评测指标

对照真实情感分数：MAE 越低越好

Pearson 相关系数越高越好

分别报告信息完整与不同缺失条件的结果

7. 机器人模仿学习：Lift 与推 T

进阶 ★★★　自行搭建环境、训练 ACT 与闭环仿真

环境选择与官方资源

MuJoCo＋robosuite；也可选择 RoboDojo

所选环境须支持 Lift 与推 T 任务

ACT 官方算法、训练与仿真代码

RoboDojo 官方仓库 / XPolicyLab

robosuite 官方仓库与安装说明

必做：环境、Lift 与对照实验

① 搭建环境，验证相机、控制与重置

② 用抓取并抬起物体的示范训练 ACT

仿真中反复观察、执行动作，测试 Lift

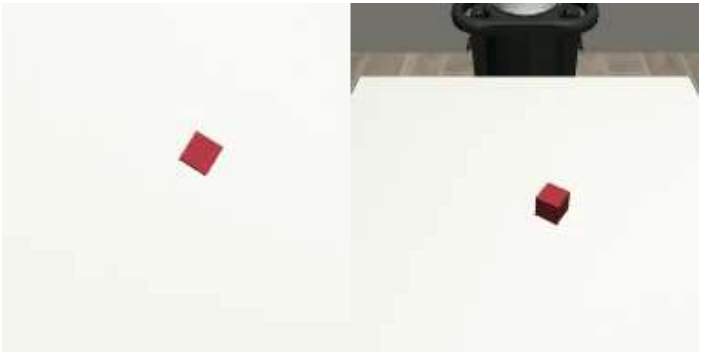
③ 比较示范数量（如20/50条）或执行长度

进阶选做：推 T

④ 用推 T 示范训练 ACT，再在仿真中测试

目标：把 T 形物体推到目标轮廓并保持

分析目标重合程度、成功比例与失败案例





ACT 成功案例：上 Lift，下推 T

评测指标

Lift：抬起成功的次数占比、所用步数

推 T：物体与目标的覆盖率、持续成功率

预先固定成功阈值、保持时长与测试初态

统一作业要求

所有选题采用相同的实验与学术表达要求

01　AI 辅助

允许 AI 辅助编程，说明主要使用环节

能够**解释并修改关**键代码

02　实验证据

提交基线、改进或对比方案及验证实验

结果可以不涨分，**结论需要实验支持**

03　公平评测

固定数据划分、标签预算与主要指标

测试集不参与调参，说明预训练模型来源

04　结果分析

报告**成功/失**败案例与方法的适用条件

可信的负面结果同样具有**价值**

提交与答辩

代码可运行，实验可追溯，关键选择可解释

提交材料：代码 + PJ报告

任务：目标、输入与输出
数据：来源、处理及训练/验证/测试划分
方法：基线、对比方案与关键设置
结果：主要指标、对照实验与图表
分析：成功/失败案例、结论与局限
说明：成员贡献、AI 使用及引用来源
附可运行代码与 README（环境和运行步骤）

Pre：展示与提问

讲清任务、数据与评价方法
说明基线、所用方法和比较思路
用核心图/表展示结果与对照
分析成功/失败案例，给出结论与局限
演示可选：图片或视频
准备回答实现

分组人数：5人一组

DDL：12月9日晚23:59（14周）

presentation：15周/16周